

Задача 1.

Аналитическая модель производительности малой CNN


Архитектура

Модель состоит из Encoder - части, состоящей преимущественно из свёрточных слоёв, и Classifier - части - из полносвязных.

FLOPs энкодера

В энкодере есть свёрточные слои, Max Pool - слой и ReLU. Разберём по порядку, каковы со свёртки.


Для размера ядра k один элемент выходного изображения будет получен из $k \times k$ участка изображения с добавлением padding. Так как padding добавляет ко входу x рамку из нулей шириной p



то эти вычисления все равно учитываются ($0 \cdot x$ - это всё равно FLOP)

Тогда, если $\text{Conv}(k, p, s, \text{bias} = \text{False})$ преобразует изображение с формой $1 \times S_1 \times S_1$ в изображение $1 \times S_2 \times S_2$, то количество FLOPs на такое преобразование будет равно

Каждый элемент $k \times k$ окна фильтра $k \times k$
 x умножается на вес фильтра и складывается с результатом y .



$$\text{FLOPs}_{\text{Conv}} = S_2^2 \cdot 2k^2 = 2k^2 S_2^2$$

При $\text{bias} = \text{True}$ добавь bias

$$\text{FLOPs}_{\text{Conv}} = 2k^2 S_2^2 + S_2^2 = (2k^2 + 1) S_2^2$$

При преобразовании $S_1 \times S_1 \times S_1$ в $S_2 \times S_2 \times S_2$ на каждый из S_2^2 выходных элементов придётся $2k^2$ операций. Итого $2k^2 S_2^2$ операций (рисовать такое - больно).

Теперь Max Pool. В этой функции нет операций сложения и умножения, только взятие максимума, это за FLOP не считается. ReLU - аналогично.

Итого, для кодировщика:

$$\begin{aligned} \text{FLOPs}_{\text{enc}} &= 2 \cdot 3 \cdot 32 \cdot 7^2 \cdot (S/2)^2 + 2 \cdot 32 \cdot 64 \cdot 5^2 \cdot (S/4)^2 + 2 \cdot 64 \cdot 128 \cdot 3^2 \cdot (S/8)^2 + \\ &+ 2 \cdot 128 \cdot 256 \cdot 1^2 \cdot (S/8)^2 + 2 \cdot 256 \cdot 256 \cdot 3^2 \cdot (S/16)^2 + 2 \cdot 256 \cdot 512 \cdot 1^2 \cdot (S/16)^2 = \\ &= 3 \cdot 49 \cdot 2^3 \cdot S^2 + 25 \cdot 2^8 \cdot S^2 + 9 \cdot 2^8 \cdot S^2 + 2^{10} \cdot S^2 + 9 \cdot 2^9 \cdot S^2 + 2^{10} \cdot S^2 = \\ &\approx 1176 \cdot S^2 + 6400 \cdot S^2 + 15360 \cdot S^2 = \underline{17712 \cdot S^2 \text{ (FLOPs)}}. \end{aligned}$$

То есть для изображения 256×256 выигрывает $17712 \cdot 2^{16} \text{ FLOPs} \approx \underline{\underline{1.16 \text{ GFLOPs}}}$.


FLOPs классификатора

Классификатор состоит из Global Avg Pool, линейных слоев и ReLU.

Разберём Global Avg Pool. Он вычисляет одно среднее для каждого канала. То есть:

$$\text{FLOPs}_{\text{Global Avg Pool}} = c_1 \cdot S_1^2$$

Линейный $f(x) = xW : \mathbb{R}^{c_1} \rightarrow \mathbb{R}^{c_2}$ будет иметь



$2 \cdot c_1$ операций на выходной элемент $\Rightarrow 2 \cdot c_1 \cdot c_2 \text{ FLOPs}$ на всё преобразование

Итого, классификатор считает

$$\text{FLOPs}_{\text{classifier}} = 512 \cdot (S/16)^2 + 2 \cdot 512 \cdot 256 + 2 \cdot 256 \cdot 100 = 313344 + 2S^2$$

то в целом — меньше по сравнению с энкодером ($\approx 0.033\%$ при $S=256$)

I/O в глобальную память

FP32 занимает 4 байта. Тогда для вершин читается и записывается

$$D_{\text{conv}} = 4 \left(\underbrace{c_1 S_1^2}_{\text{вход, чтение}} + \underbrace{c_1 c_2 k^2}_{\text{веса, чтение}} + \underbrace{c_2 S_2^2}_{\text{выход, запись}} \right)$$

байт.

Для линейного слоя аналогично:

$$D_{lin} = 4(C_1 + C_1 \cdot C_2 + C_2)$$

Вычисляем количество элементов в активациях:

$$3S^2 \rightarrow 8S^2 \rightarrow 2S^2 \rightarrow 4S^2 \rightarrow 2S^2 \rightarrow 4S^2 \rightarrow S^2 \rightarrow 2S^2 \rightarrow 512 \rightarrow 256 \rightarrow 100$$

И тогда для кодирования выходит

$$D_{enc} = 4(883296 + 89S^2)$$

и для классификатора:

$$D_{classifier} = 4(158820 + 2S^2)$$

байт.

Снова кодирование создает заметно больше ресурсов, чем классификатор.

Задержка и энергия

Для Т4 GPU скорость вычислений в FP32 равна 8.1 TFLOP/s, а пропускная способность памяти ~ 320 ГБ/с. Энергопотребление - 70W.

Будем оптимизировать и примем $mfu = 0.5$. Для упрощения расчетов предположим, что чтение данных и вычисления происходят строго последовательно.

Тогда:

$$T(s) = \frac{F(s)}{8.1 \cdot 10^{12} \cdot mfu} + \frac{D(s)}{320 \cdot 10^6} = \frac{17714S^2 + 313344}{4.05 \cdot 10^{12}} + \frac{4(1042116 + 91S^2)}{320 \cdot 10^9}$$

Увеличение батча можно считать линейным увеличением FLOPs и не-весовой части D:

$$T(s, B) = B \cdot \frac{17714S^2 + 313344}{4.05 \cdot 10^{12}} + \frac{4(1042116 + 91B S^2)}{320 \cdot 10^9}$$

Количество энергии же - линейно зависящее от времени

$$E(s, B) = 70 T(s, B).$$