Sparse Attention as Compact Kernel Regression

Saul Santos, Nuno Gonçalves, Daniel C. McNamee,
Marcos Treviso, André F. T. Martins

Егор Прокопов

Главная идея

Модель может лучше извлекать нужную информацию, если присваивать достаточно непохожим ключам ровно нулевой вес.

Результат работы внимания - получение взвешенной суммы векторов-значений:

$$y = \sum_{i=1}^{n} p_i v_i, \qquad p_i \geq 0, \qquad \sum_i p_i = 1.$$

В обычном softmax-механизме внимания веса определяются нормированными скалярными произведениями запроса и ключа. Каждый ключ получает положительный вес. Если ключей много, то их суммарный вклад "ненужных" может уменьшать влияние "полезных".

Внимание как ядерная регрессия

Веса внимания задает функция близости между запросами и ключами - кернел.

$$p_i = \frac{\kappa(q, k_i)}{\sum_j \kappa(q, k_j)}, \qquad y(q) = \sum_i p_i v_i.$$

Кернел $\kappa \geq 0$ определяет, насколько сильно ключ влияет на ответ.
При $\|q\| = \|k_i\| = 1$ сходство и расстояние связаны:

$$s_i = q^\mathsf{T} k_i, \qquad d_i^2 = \|q - k_i\|^2 = 2 - 2qk^\top = 2 - 2s_i.$$

Гауссовское ядро даёт softmax-внимание

Используем ядро с шириной $h > 0$:

$$\kappa_h(q, k_i) = \exp\left(-\frac{\|q - k_i\|^2}{2h^2}\right).$$

Для единичных норм:

$$\kappa_h(q, k_i) = \underbrace{\exp(-1/h^2)}_{\text{общий множитель}} \exp(s_i/h^2).$$

Общий множитель сокращается при нормировании:

$$p_i = \frac{\exp(s_i/h^2)}{\sum_j \exp(s_j/h^2)} = \mathrm{softmax}(s/h^2)_i.$$

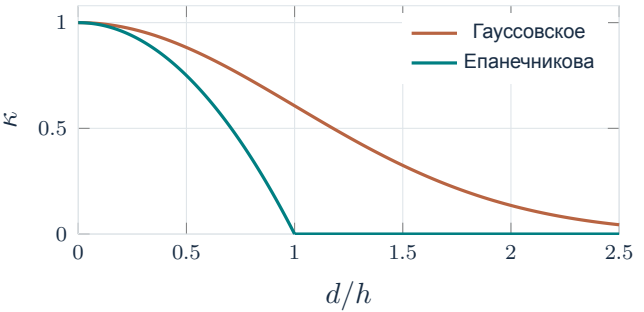
Компактное ядро обнуляет дальние ключи

Ядро Епанечникова:

$$\kappa_h(q, k_i) = \left[1 - \frac{d_i^2}{h^2}\right]_+$$

$[x]_+ = \max(0, x)$
$h > 0$ — радиус отсечения:

$$d_i \geq h \implies p_i = 0$$



Формы ядер без констант нормировки.

Близость определяется в пространстве ключей. Можно сказать, что позиция не участвует в вычислении, но она участвует опосредованно, через трансформирование векторов посредством позиционного кодирования

Важно: замена ядра меняет механизм внимания, оно не тождественно softmax-вниманию.

Разреженное внимание через компакт-ядра: фиксированный радиус через нормированный ReLU

Подставим $d_i^2 = 2 - 2s_i$ в компактное ядро:

$$w_i = \left[1 - \frac{2 - 2s_i}{h^2}\right]_+ = \frac{2}{h^2}\,[s_i - c]_+\,, \qquad c = 1 - \frac{h^2}{2}.$$

После сокращения общего множителя:

$$p_i = \frac{[s_i - c]_+}{\sum_j [s_j - c]_+}.$$

Порог c задаётся заранее выбранным радиусом h. Число активных ключей зависит от их сходства с запросом.

Адаптивный радиус приводит к sparsemax

Введём температуру $\gamma > 0$ и перепишем те же веса:

$$w_i = \frac{2\gamma}{h^2}\left[\frac{s_i}{\gamma} - \tau\right]_+, \qquad \tau = \frac{1}{\gamma} - \frac{h^2}{2\gamma}.$$

Выберем τ так, чтобы сумма выражений в скобках была единицей:

$$\sum_i \left[\frac{s_i}{\gamma} - \tau\right]_+ = 1.$$

Тогда после нормирования:

$$p_i = \left[\frac{s_i}{\gamma} - \tau\right]_+ = \mathrm{sparsemax}(s/\gamma)_i, \qquad h^2 = 2 - 2\gamma\tau.$$

Таким образом, порог и соответствующий ему радиус подстраиваются под текущие ключи.

Top-k наиболее похожих ключей

Сначала вычисляем скалярное произведение запроса с каждым ключом:

$$s_i = q^\mathsf{T} k_i, \qquad S_k = \mathrm{TopK}(s), \qquad 1 \le k \le n.$$

S_k - индексы k ключей с наибольшими значениями s_i. При единичных нормах это также k ближайших к запросу ключей.

Остальным ключам присваиваем нулевой вес.

top-k softmax нормирует веса выбранных ключей:

$$p_i = \begin{cases} \dfrac{\exp(s_i/\gamma)}{\sum_{j \in S_k} \exp(s_j/\gamma)}, & i \in S_k, \\ 0, & i \notin S_k, \end{cases} \qquad \gamma > 0.$$

В uniform top-k все выбранные ключи получают одинаковый вес $1/k$.

Сравнение Top-k и ReLUmax

Top-k выбирает k ключей с наибольшим сходством. ReLUmax оставляет ключи, достаточно близкие по сходству к лучшему:

$$m = \max_j s_j, \qquad w_i = \left[b + \frac{s_i - m}{h^2}\right]_+^r,$$

$$p_i = \frac{w_i}{\sum_j w_j}, \quad b, h, r > 0.$$

Ненулевой вес получают ключи, для которых

$$s_i > m - bh^2.$$

ReLUmax фиксирует допустимое отставание от максимума. Если почти лучших ключей много, то в вычислении участвуют многие ключи. Если почти лучших ключей мало, то в вычислении участвует мало ключей (преимущественно - только лучшие).

Итоги

- Разреженное внимание можно представить через компакт-кернел.
- Отсечение слабых совпадений помогает в ряде задач, но результат зависит от нормировки и самой задачи.
- Нулевые веса можно использовать для ускорения вычислений, но подходяшего раздела в статье нет